

Datawhale 开源社区

深入理解计算机系统(11)

Computer Systems A Programmer's Perspective

CSAPP

李岳昆、易远哲 realyurk@gmail.com、yuanzhe.yi@outlook.com

2021 年 12 月 18 日



第一部分

优化程序性能-I

优化程序性能



我们先看看下面的代码:

```
struct
void twiddle1(long *xp, long *yp) {
     *xp += *yp;
     *xp += *yp;
4 }
6 void twiddle2(long *xp, long *yp) {
     *xp += 2 * *yp;
```

优化编译器的能力和局限性



在上一页的两段代码中,函数 twiddle2 的效率更高,因为它只要求 3 次内存引用 (读 *xp,读 *yp,写 *xp),而 twiddle1 需要 6 次 (2 次读 *xp, 2 次读 *yp, 2 次写 *xp)。

不过,如果 xp = yp,那么函数 twiddle1 实际的操作是将 xp 的值增加 4 倍。而函数 twiddle2 则是将 xp 的值增加了 3 倍。

由于编译器不知道 xp 与 yp 是否可能相等,因此 twiddle2 不能作为 twiddle1 的优化版本。



考虑下面的代码:

```
struct
1 long f();
3 long func1() {
   return f() + f() + f() + f();
5 }
7 long func2() {
     return 4 * f();
9 }
```

先不考虑函数 f 的具体内容,可以看到, func2 只调用 f 一次, 而 func1 调用 f 四次。但如果考虑函数 f 如下:

```
struct

1 long counter = 0;
2 
3 long f() {
4    return counter++;
5 }
```

显然,对于这样的 f, func1 会返回 6, 而 func2 会返回 0。这种情况编译器也是无法判断的,因此编译器也无法做出这种优化。

程序性能的表示



对于一个程序,如果我们记录该程序的数据规模以及对应的运行所需的时钟周期,并通过最小二乘法来拟合这些点,我们将得到形如 y=a+bx 的表达式,其中 y 是时钟周期,x 是数据规模。当数据规模较大时,运行时间就主要由线性因子 b 来决定。这时候,我们将 b 作为度量程序性能的标准,称为**每元素的周期数(Cycles Per Element, CPE)**。



为了方便说明, 先声明一个如下的结构:

```
typedef

typedef struct {
   long len;
   data_t *data;
} vec_rec, *vec_ptr
```

这个声明用 data_t 来表示基本元素的数据类型。



先考虑如下的代码:

```
combine1
void combine1(vec_ptr v, data_t *dest) {
      long i;
      *dest = IDENT;
      for (i = 0; i < vec_length(v); i++) {</pre>
           data_t val;
           get_vec_element(v, i, &val);
           *dest = *dest OP val:
10 }
```

上一页的代码中,循环体每执行一次,都会调用一次函数 vec_length,但数组的长度是不变的,那么可以考虑将 vec_length 移出循环体来提升效率:

```
combine2
void combine2(vec_ptr v, data_t *dest) {
     long i:
     long length = vec_length(v);
     *dest = IDENT:
     for (i = 0; i < length; i++) {</pre>
         data t val:
          get vec element(v, i, &val);
         *dest = *dest OP val:
```



```
combine2
 data_t *get_vec_start(vec_ptr v) {
      return v -> data:
5 void combine3(vec ptr v, data t *dest) {
      long i;
      long length = vec_length(v);
      data_t *data = get_vec_start(v);
      *dest = IDENT;
11
      for (i = 0; i < length; i++)</pre>
12
           *dest = *dest OP data[i];
13 }
```

减少过程调用



在上一页的代码中,我们消除了循环体中的所有调用。但实际上,这样的改变不会 带来性能的提升,在整数求和的情况下还会造成性能下降。这是因为内循环中还有 其他的操作形成了瓶颈。



先看看 combine3 的 x86-64 汇编代码:

```
assembly
.L17:
 vmovsd (%rbx), %xmm0
 vmulsd (%rdx), %xmm0, %xmm0
 vmovsd %xmm0, (%rbx)
  addq $8, %rdx
  cmpq %rax, %rdx
  ine .L17
```



通过上面的汇编代码可以看到,每次迭代时,累积变量的数值都要从内存中读出再写入到内存,这样的读写是很浪费的,而且是可以消除的:

```
combine4
void combine4(vec_ptr v, data_t *dest) {
     long i:
     long length = vec_length(v);
     data_t *data = get_vec_start(v);
     data_t acc = IDENT;
     for (i = 0; i < length; i++)</pre>
          acc = acc OP data[i]:
     *dest = acc:
```

现代处理器的优化



近期的 Intel 处理器是**超标量(superscalar**)的,意思是它可以在每个时钟周期执行多个操作。此外还是 **乱序的(out-of-order**),意思是指令执行的顺序不一定与机器级程序中的顺序一致。

这样的设计使得处理器能够达到更高的并行度。例如,在执行分支结构的程序时,处理器会采用**分支预测(branch prediction)**技术,来预测是否需要选择分支,同时还预测分支的目标地址。

此外还有一种**投机执行(speculative execution)**技术,意思是处理器会在分支之前就执行分支之后的操作。如果预测错误,那么处理器就会将状态重置到分支点的状态。



所谓循环展开,指的是通过增加每次迭代计算的元素数量来减少循环的迭代次数。 考虑如下的程序:

```
psum1

1 void psum1(float a[], float p[], long n) {
2    long i;
3    p[0] = a[0];
4    for (i = 1; i < n; i++)
5         p[i] = p[i-1] + a[i];
6 }</pre>
```

下一页中将展示循环展开后的函数。

通过对 psum1 函数进行循环展开, 能够使迭代次数减半:

```
psum2
void psum2(float a[], float p[], long n) {
      long i;
      p[0] = a[0];
      for (i = 1; i < n - 1; i += 2) {
          float mid_val = p[i-1] + a[i];
          p[i] = mid_val;
          p[i+1] = mid val + a[i+1]:
      if (i < n)
          p[i] = p[i-1] + a[i];
10
```

寄存器溢出



对于循环展开,很自然地考虑如下问题:是否展开的次数越多,性能提升越大?实际上,循环展开需要维护多个变量,一旦展开的次数过多,没有足够的寄存器保存变量,那么就需要将变量保存到内存中,这就会导致访存时间消耗增加。即便是在×86-64 这样拥有足够多寄存器的架构中,循环也很可能在寄存器溢出之前就达到吞吐量限制,从而无法持续提升性能。